


Summarizer

Summarization — Best way to make teacher summaries



Extractive

Textrank Algorithm

Encoder Decoder

Google mT5

Abstractive

LLM (gemini / gpt)



Dataset creation

LLM Teacher Models

Multiple LLM-based generation approaches

50K+

training summaries



Why this approach

- mT5-base did not produce usable Sinhala summaries
- Teacher models were used to create training targets
- The final model learns from these teacher summaries

Summarization — Extractive vs Abstractive vs mT5

FINE-TUNED ABSTRACTIVE LLM
summarization_sinllama_v07

🏆 Best Output

🌸 ★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

56% Abstractive (44% Verbatim)

📄

වෛද්‍ය නිලධාරීන්ගේ ඉල්ලීම මත
වැලිකඩ බන්ධනාගාරයේ හිටපු ප්‍රධාන
වෛද්‍ය නිලධාරී නිර්මලී
තේනුවර මහත්මිය වහාම ක්‍රියාත්මක
වන පරිදි කොළඹ ජාතික රෝහලකට
ස්ථාන මාරු කර ඇත.

ENCODER-DECODER BASELINE
mT5 Base (Teacher)

📄 ★★★★★ (Decent)

Standard baseline — acceptable compression but can produce generic or clipped phrasing

OUTPUT

100% Abstractive (0% Verbatim)

📄

01.01.201mybmybmybksuAnatomAnatomks
娱乐彩票AnatomAnatom 01.01.201
01.01.201AnatomAnatomintâlnAnatomAnato
今𑖦ksuksuksuAnatom Ngh Ngh
Nghksu 01.01.201 01.01.201 Ngh
01.01.201 01.01.201
01.01.201ksuAnatomksuksuapparel
Gonz Ngh Genev Genev
GenevAnatomAnatoml'ovaniksuksu
01.01.201ksu Ngh Ngh GenevAnatom
GonzksuAnatom
GonzAnatomAnatomphysiologphysiologphy
Gonz Gonz Gonzksuksu Gle Gleksuksu
lezenstvaksuksu
anatomAnatomAnatom anatomAnatom

EXTRACTIVE (COPY-PASTE)
TEXTRANK (Extractive)

🚀 Fastest

🔪 ★★ (Rigid)

Verbatim extraction — cuts and pastes sentences without human-like rewrite

OUTPUT

2% Abstractive (98% Verbatim)

📄

වැලිකඩ බන්ධනාගාර රෝහලේ
වැඩබලන වෛද්‍ය නිලධාරී නිර්මලී
තේනුවර මහත්මිය කොළඹ ජාතික
රෝහලට ස්ථාන මාරු කර තිබේ. අදාළ
වෛද්‍යවරුන් විසින් වැඩබලන වෛද්‍ය
නිලධාරී නිර්මලී තේනුවර මහත්මියගේ
වෘත්තීය විෂමාවාර පිළිබඳව කරුණු
26ක් අනුදුලත් වාර්තාවක් සෞඛ්‍ය
අමාත්‍යවරයා වෙත බාරදුන් බව
අමාත්‍යාංශය ප්‍රකාශ කළේය. ඒ අනුව
නව වැඩබලන ප්‍රධාන වෛද්‍ය
නිලධාරීවරයා වශයෙන් ජේ.කේ
මල්වත්තගේ මහතා පත් කිරීමට
නියමිත බව සඳහන්ය.

Summarization — Actual Evaluation Results

Quantitative Linguistic Metrics Matrix							Green = Target · Amber = Acceptable · Red = Poor	
MODEL	APPROACH	EXACT MATCH	ROUGE-L	ROUGE-1	ROUGE-2	BERTSCORE (SEMANTIC)	GLEU	CHAR-F1
summarization_sinllama_v07	Fine-tuned Abstractive LLM	No	50.9%	50.9%	47.9%	91.1%	30.8%	-
mt5-base	Encoder-Decoder Baseline	No	0.2%	0.2%	0.0%	74.1%	0.0%	-
textrank	Extractive (Copy-Paste)	No	25.2%	25.2%	23.6%	90.4%	12.8%	-

ROUGE : checks if we got the words and phrases correct

BERTScore : checks if the meaning is 100% accurate

GLEU : checks that it's clean without repeating nonsenses

Summarization — Model Difference

V04 }
V05 } One Summary Length



Main Problem in v04 and v05

With v04/v05, the model was essentially trained around one target summary style/length. It therefore learned a **fixed-length tendency**

short

FINE-TUNED
ABSTRACTIVE LLM
summarization_...

Best OutputFastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

48% Abstractive (52% Verbatim)

📄

ඌලිකඩ බන්ධනාගාරරෝහලේ වැඩබලන වෛද්‍ය නිලධාරී නිර්මලී තේනුවරමහමල්පිය කොළඹ ජාතික රෝහලට ස්ථාන මාරු කර ඇත. ඇගේ වෘත්තීය විෂමාවාරය පිළිබඳ කරුණු 26ක් ඇතුළත් වාර්තාවක් සෞඛ්‍ය අමාත්‍යවරයාට බාර දී ඇති අතර, මේ සම්බන්ධයෙන් විමර්ශනයක් ද ආරම්භ කර ඇත. නව වැඩබලන ප්‍රධාන වෛද්‍ය නිලධාරීවරලෙස ජේ.කේ මල්වත්ත මහතාගේ පත් කිරීමට නිශ්චය වේ.

Compression

125 → 48 words (62% condensed)

Speed: 19960.31 ms

Rate: 9.02 tok/s

Output: 180 tok

medium

FINE-TUNED
ABSTRACTIVE LLM
summarization_...

Best OutputFastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

48% Abstractive (52% Verbatim)

📄

ඌලිකඩ බන්ධනාගාරරෝහලේ වැඩබලන වෛද්‍ය නිලධාරී නිර්මලී තේනුවරමහමල්පිය කොළඹ ජාතික රෝහලට ස්ථාන මාරු කර ඇත. ඇගේ වෘත්තීය විෂමාවාරය පිළිබඳ කරුණු 26ක් ඇතුළත් වාර්තාවක් සෞඛ්‍ය අමාත්‍යවරයාට බාර දී ඇති අතර, මේ සම්බන්ධයෙන් විමර්ශනයක් ද ආරම්භ කර ඇත. නව වැඩබලන ප්‍රධාන වෛද්‍ය නිලධාරීවරලෙස ජේ.කේ මල්වත්ත මහතාගේ පත් කිරීමට නිශ්චය වේ.

Compression

125 → 48 words (62% condensed)

Speed: 20189.93 ms

Rate: 8.92 tok/s

Output: 180 tok

Long

FINE-TUNED
ABSTRACTIVE LLM
summarization_...

Best OutputFastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

48% Abstractive (52% Verbatim)

📄

ඌලිකඩ බන්ධනාගාරරෝහලේ වැඩබලන වෛද්‍ය නිලධාරී නිර්මලී තේනුවරමහමල්පිය කොළඹ ජාතික රෝහලට ස්ථාන මාරු කර ඇත. ඇගේ වෘත්තීය විෂමාවාරය පිළිබඳ කරුණු 26ක් ඇතුළත් වාර්තාවක් සෞඛ්‍ය අමාත්‍යවරයාට බාර දී ඇති අතර, මේ සම්බන්ධයෙන් විමර්ශනයක් ද ආරම්භ කර ඇත. නව වැඩබලන ප්‍රධාන වෛද්‍ය නිලධාරීවරලෙස ජේ.කේ මල්වත්ත මහතාගේ පත් කිරීමට නිශ්චය වේ.

Compression

125 → 48 words (62% condensed)

Speed: 20090.54 ms

Rate: 8.96 tok/s

Output: 180 tok

Summarization — Model Difference

V06

V07



Three Summary Lengths



Main Problem in v04 and v05

v06 introduced **three target summary lengths** instead of one fixed-length output.
The model was trained to generate **Short, Medium, or Long** summaries according to the requested length.

short

FINE-TUNED
ABSTRACTIVE LLM
summarization_...

🏆 Best Output ⚡ Fastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

56% Abstractive (44% Verbatim)

📄

වෛද්‍ය නිලධාරීන්ගේ ඉල්ලීම මත වැලිකඩ බන්ධනාගාරයේ නිවසු ප්‍රධාන වෛද්‍ය නිලධාරී නිර්මලී තේනුවරමහත්මිය වහාම ක්‍රියාත්මක වන පරිදි කොළඹ ජාතික රෝහලකට ස්ථාන මාරු කර ඇත.

Compression

125 — 25 words (80% condensed)

Speed: 9137.55 ms

Rate: 8.76 tok/s

Output: 80 tok

medium

FINE-TUNED
ABSTRACTIVE LLM
summarization_...

🏆 Best Output ⚡ Fastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

65% Abstractive (35% Verbatim)

📄

වෛද්‍ය නිලධාරීන්ගේ ඉල්ලීම මත සහ විශාම්වාර්තා සැලකිල්ලට ගනිමින් පොළොන්නරුව බන්ධනාගාරයේ නිවසු ප්‍රධාන වෛද්‍ය නිලධාරී නිර්මලී තේනුවරමහත්මිය වහාම ක්‍රියාත්මක වන පරිදි සිය ධූරයෙන් ඉවත් කර ඇත. ඇයගේ ප්‍රතිස්ථාපනය සඳහා ජේ.කේ මල්වත්තගේ මහතා පත්කර තිබේ.

Compression

125 — 34 words (73% condensed)

Speed: 14906.85 ms

Rate: 8.72 tok/s

Output: 130 tok

Long

FINE-TUNED
ABSTRACTIVE LLM
summarization_...

🏆 Best Output ⚡ Fastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

51% Abstractive (49% Verbatim)

📄

වැලිකඩ බන්ධනාගාරයේ වැඩබලන වෛද්‍ය නිලධාරී නිර්මලී තේනුවරමහත්මියව කොළඹ ජාතික රෝහලට ස්ථාන මාරු කර ඇත. මෙම තීරණය වෛද්‍යවරුන් 19 දෙනාගේ ඉල්ලීම මත ගන්නා ලදී. අමාත්‍යාංශය මගින් ඇය පිළිබඳ වාර්තාව ඉදිරිපත් කළ අතර, එය විමර්ශනය සඳහා පොලිස්පති වරයාට යවන ලදී. නව වෛද්‍යවරයා ලෙස ජේ.කේ.මල්වත්තගේ මහතා පත් කරනු ඇතැයි නියමිතය.

Compression

125 — 51 words (59% condensed)

Speed: 22455.83 ms

Rate: 8.91 tok/s

Output: 200 tok

Summarization — Model Difference

V04

V05

V06

V07

}

}

One Summary Length

Three Summary Lengths

Three Controlled Lengths

Short ~ 10%

Medium ~ 20%

Long ~ 35%

Different targets let the model follow the requested summary length insted of producing one fixed length output

FINE-TUNED ABSTRACTIVE LLM

summarization_sinllama_v07

Best Output

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

56% Abstractive (44% Verbatim)

වෛද්‍ය නිරෝධායනයේ ඉල්ලීමකට
වැඩිකඩ බන්ධනාගාරයේ නිවස ප්‍රධාන
වෛද්‍ය නිරෝධායන නිර්මාණය
නේත්‍රවර්ණය වහාම ක්‍රියාත්මක
වන පරිදි කොළඹ ජාතික රෝහලකට
ස්ථාන මාරු කර ඇත.

Compression

125 — 25 words (80% condensed)

Speed: 8935.06 ms

Rate: 8.95 tok/s

Output: 80 tok

ROUGE-L

51%

BERTScore

91%

GLEU

31%

Char-F1

NaN%

FINE-TUNED ABSTRACTIVE LLM

summarization_sinllama_v06

Fastest

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

62% Abstractive (38% Verbatim)

වෛද්‍ය නිර්මාණය නේත්‍රවර්ණයට
එරෙහිව පවතින වෘත්තීය
විෂමතාවය පිළිබඳ විමර්ශනයක්
ඇරඹීමට පියවර ගෙන ඇත.

Compression

125 — 13 words (90% condensed)

Speed: 8929.46 ms

Rate: 8.96 tok/s

Output: 80 tok

ROUGE-L

45%

BERTScore

89%

GLEU

27%

Char-F1

NaN%

FINE-TUNED ABSTRACTIVE LLM

summarization_sinllama_v05

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

54% Abstractive (46% Verbatim)

වැලිකඩ බන්ධනාගාරයේ නිවස
වැඩිකඩ වෛද්‍ය නිරෝධායන නිර්මාණය
නේත්‍රවර්ණයට එරෙහිව ඉදිරිපත්
කළ වාර්තාවල අඩංගු වූ කරුණු 26කට
අදාළව විමර්ශනයක් ආරම්භ කර ඇත.
මෙම විමර්ශනය අවසන් වීමෙන් පසු,
ජේ.කේ මල්වත්තගේ මහතා වැලිකඩ
බන්ධනාගාරයේ වැඩිකඩ ප්‍රධාන
වෛද්‍ය නිරෝධායන ලෙස පත් කරනු
ලැබේ.

Compression

125 — 41 words (67% condensed)

Speed: 19848.77 ms

Rate: 9.07 tok/s

Output: 180 tok

ROUGE-L

25%

BERTScore

88%

GLEU

11%

Char-F1

NaN%

FINE-TUNED ABSTRACTIVE LLM

summarization_sinllama_v04

★★★★★ (Human-grade)

Natural journalistic rewrite — synthesizes key facts into fluent, coherent Sinhala prose

OUTPUT

48% Abstractive (52% Verbatim)

වැලිකඩ බන්ධනාගාරයේ නිවස
වැඩිකඩ වෛද්‍ය නිරෝධායන නිර්මාණය
නේත්‍රවර්ණයට එරෙහිව කොළඹ ජාතික
රෝහලට ස්ථාන මාරු කර ඇත. ඇගේ
වෘත්තීය විෂමතාවය පිළිබඳ කරුණු
26ක් ඇතුළත් වාර්තාවක් සෞඛ්‍ය
අමාත්‍යවරයාට බාර දී ඇති අතර, මේ
සම්බන්ධයෙන් විමර්ශනයක් ද ආරම්භ
කර ඇත. නව වැඩිකඩ ප්‍රධාන වෛද්‍ය
නිරෝධායන ලෙස ජේ.කේ මල්වත්ත
මහතාගේ පත් කිරීමට නිශ්චය වේ.

Compression

125 — 48 words (62% condensed)

Speed: 19540.06 ms

Rate: 9.21 tok/s

Output: 180 tok

ROUGE-L

30%

BERTScore

89%

GLEU

17%

Char-F1

NaN%

Quantitative Linguistic Metrics Matrix								
Green = Target · Amber = Acceptable · Red = Poor								
MODEL	APPROACH	EXACT MATCH	ROUGE-L	ROUGE-1	ROUGE-2	BERTSCORE (SEMANTIC)	GLEU	CHAR-F1
summarization_sinllama_v07	Fine-tuned Abstractive LLM	No	50.9%	50.9%	47.9%	91.1%	30.8%	-
summarization_sinllama_v06	Fine-tuned Abstractive LLM	No	45.2%	53.2%	34.4%	89.2%	26.8%	-
summarization_sinllama_v05	Fine-tuned Abstractive LLM	No	25.5%	30.1%	19.5%	87.6%	11.4%	-
summarization_sinllama_v04	Fine-tuned Abstractive LLM	No	30.4%	30.4%	29.3%	88.9%	16.7%	-

3 lengths: Short • Medium • Long | v04 → v05 → v06 → v07 | v07 = cleaner data, comparable performance

B7 / Summarization